UNIVERSIDAD NOVA

Proyecto de Big Data y Gobierno de Datos

Del dato disperso a la información útil
PostgreSQL · R · Spark/sparklyr · Shiny · DAMA-DMBOK

Autor: Fernando Eleodoro Rojas Alcedo

Curso: Big Data

Versión: Octubre de 2026

Presentación

Este informe explica cómo se organizó una práctica de analítica para el caso ficticio de Universidad Nova. El trabajo reúne datos simulados, los prepara con R, los almacena en PostgreSQL y plantea su análisis con Spark/sparklyr. Los resultados se muestran en un tablero Shiny. Además de describir la parte técnica, se proponen reglas para que los datos tengan responsables, sean más confiables y se utilicen con cuidado.

Una aclaración importante: las cifras de este documento proceden de datos sintéticos. Sirven para probar el flujo de trabajo, no describen la situación real de una universidad. Algunas medidas de gobierno se presentan como recomendaciones y todavía requieren implementación y pruebas.

1. ¿Qué problema busca resolver el proyecto?

En el caso planteado, Universidad Nova tiene alrededor de 15.000 estudiantes, 1.200 docentes y 700 trabajadores administrativos. La información se encuentra repartida entre distintos sistemas y no siempre coincide. En un escenario así, un mismo estudiante podría aparecer con datos distintos, dos reportes podrían entregar cifras diferentes y no siempre estaría claro quién debe corregir un registro.

El problema no se resuelve únicamente instalando una herramienta. Antes de confiar en los indicadores, hace falta acordar qué significa cada dato, quién responde por él, quién puede consultarlo y cómo se comprueba su calidad. Por eso el proyecto combina una demostración técnica con una propuesta de gobierno de datos basada en DAMA-DMBOK.

Objetivos del trabajo

- Organizar un conjunto de datos académico simulado en una base relacional.
- Preparar y transformar los registros mediante scripts R.
- Explorar el procesamiento y la modelación con Spark/sparklyr.
- Mostrar indicadores y filtros en una aplicación Shiny.
- Proponer responsables, controles de calidad, medidas de seguridad y formas de seguir el origen de los datos.

Qué se ha comprobado y qué no

En una revisión anterior se verificaron 15.000 filas en cada una de estas tablas: nova_raw.estudiantes, nova_raw.matriculas y nova_analytics.modelo_estudiantes. También se revisó la sintaxis de los scripts principales y se registró la existencia de archivos con métricas y matriz de confusión. El tablero Shiny llegó a visualizarse. La ejecución completa de Spark y los filtros del tablero deben comprobarse otra vez antes de grabar la demostración final.

> Este informe no afirma que la solución esté instalada en una universidad real ni que se hayan desplegado todos los controles de gobierno descritos más adelante.

2. Inventario inicial de datos

El inventario permite saber qué información se maneja, de dónde viene y quién debería responder por ella. La tabla es una propuesta inicial para el caso académico; en una implantación real, cada área tendría que validar los campos, la clasificación y los plazos de conservación.

Dominio	Ejemplos	Origen / destino	Responsable sugerido	Sensibilidad
Académico	Código, programa, ciclo, condición	Sistema académico → PostgreSQL	Secretaría académica	Alta: identifica y describe trayectoria educativa
Matrícula	Periodo, curso, estado	Matrícula simulada → ETL → base analítica	Oficina de matrícula	Alta: historial del estudiante
Asistencia	Sesiones, porcentaje de asistencia	Fuente simulada → capa analítica	Área académica / docente	Media/alta: refleja comportamiento educativo
Personal	Unidad, rol, estado laboral	Fuente administrativa simulada	Recursos Humanos	Alta: información del trabajador
Analítica	Grupo o riesgo sintético	Modelo analítico y salida del modelo	Analista con autorización	Alta: puede malinterpretarse si se usa sin contexto

Qué debería registrar el catálogo

Para cada conjunto conviene anotar nombre, descripción, sistema de origen, fecha de actualización, responsable funcional, custodio técnico, reglas de calidad, sensibilidad, usuarios autorizados, finalidad permitida y plazo de conservación. También es útil registrar qué transformaciones se hicieron y qué informe o modelo utiliza el resultado.

Reglas de calidad que conviene aplicar

Como mínimo, se deberían detectar identificadores repetidos, matrículas sin estudiante asociado, categorías escritas de distintas maneras, valores faltantes y porcentajes fuera de rango. El proceso ETL debería dejar constancia de cuántas filas entraron, cuántas se cargaron y cuáles fueron rechazadas, junto con el motivo. Así es posible investigar diferencias sin tener que adivinar qué ocurrió.

3. Personas y áreas que intervienen

El gobierno de datos necesita participación de las áreas que conocen la información y de quienes mantienen los sistemas. TI puede garantizar que una base funcione, pero no debería decidir por sí sola qué significa una condición académica o quién tiene derecho a corregirla.

Actor	Qué le corresponde hacer	Acceso sugerido
Rectoría / comité de datos	Aprobar prioridades, políticas y responsables; revisar riesgos relevantes.	Indicadores agregados; excepciones justificadas.
Secretaría académica	Definir los datos académicos y resolver discrepancias de registro.	Registros identificables necesarios para su función.
Docentes / tutores	Registrar y corregir asistencia o actividad de sus cursos.	Cursos y estudiantes a su cargo.
TI / administrador de base	Gestionar cuentas, respaldo, disponibilidad y cambios técnicos.	Privilegios técnicos auditados.
Analistas de datos	Preparar conjuntos, documentar modelos y explicar limitaciones.	Datos agregados o seudonimizados por defecto.
Seguridad / asesoría legal	Revisar incidentes, conservación, cumplimiento y controles.	Acceso justificado para auditoría.
Proveedores externos	Prestar el servicio según contrato e instrucciones acordadas.	Acceso mínimo, temporal y supervisado.

Medidas recomendadas

La universidad debería asignar permisos según el trabajo de cada persona, revisar las cuentas periódicamente y retirar accesos cuando ya no sean necesarios. También conviene registrar exportaciones y cambios administrativos, evitar que las contraseñas aparezcan en scripts y utilizar datos sintéticos en las prácticas. Si se trabajara con datos reales, habría que minimizar la información identificable y definir cómo responder ante una fuga o acceso indebido.

Estas medidas forman parte de la propuesta. Su inclusión en el informe no significa que ya estén activas en un sistema institucional.

4. Arquitectura de la solución

La arquitectura se organizó por etapas para que sea más sencillo identificar dónde aparece un error y qué componente debe corregirse. R prepara los datos, PostgreSQL conserva las tablas, Spark/sparklyr se utiliza para el trabajo analítico y Shiny presenta los resultados de forma visual.

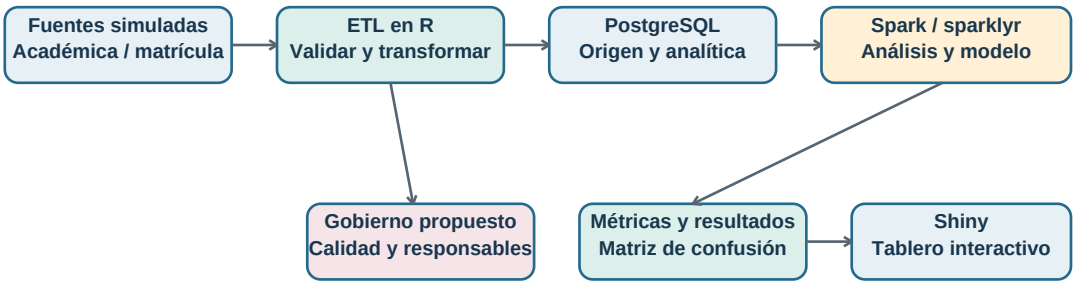

Esquema lógico del proyecto; los controles de gobierno se plantean como mejoras, no como funciones ya desplegadas.

Por qué se eligieron estas herramientas

R: permite escribir los pasos de preparación como scripts y repetirlos con las mismas reglas.
PostgreSQL: ofrece almacenamiento relacional y consultas SQL; permite definir claves y permisos, siempre que se configuren y prueben.
Spark/sparklyr: permite explorar procesamiento distribuido y técnicas de clasificación o agrupación desde R.
Shiny: facilita mostrar indicadores y permitir que el usuario explore resultados con filtros.
Git/GitHub: ayuda a conservar el historial de cambios y compartir el código. La URL pública del repositorio todavía debe incorporarse y verificarse antes de la entrega.

Flujo general

Datos simulados → ETL y validaciones → tablas de origen → modelo analítico → procesamiento y evaluación → tablero. De forma transversal, el gobierno de datos define responsables, permisos, criterios de calidad y documentación del origen de la información.

El diagrama representa el flujo lógico del proyecto. No pretende demostrar que ya exista un catálogo empresarial o un linaje automatizado.

5. Preparación de datos y modelo analítico

El ETL —extraer, transformar y cargar— es importante porque un modelo no corrige por sí solo los errores que encuentra en los datos. Antes de cargar información, conviene comprobar la estructura de las columnas, normalizar categorías, revisar claves y registrar valores que no cumplen las reglas. Después de la carga, se comparan los conteos para detectar pérdidas o duplicaciones.

En la revisión previa quedaron registrados 15.000 estudiantes, 15.000 matrículas y 15.000 filas en la tabla analítica modelo_estudiantes. Para que el resultado pueda reproducirse, el script debería dejar constancia de la fecha de ejecución, las filas procesadas, las reglas aplicadas y los errores encontrados.

Uso de Spark/sparklyr

Spark se incorpora como entorno de procesamiento para explorar tareas analíticas desde R. Antes de presentar el trabajo, falta repetir una comprobación completa de conexión, ejecución y resultados, y conservar una evidencia que muestre qué script se ejecutó y qué produjo. Es preferible reconocer esta verificación pendiente que afirmar que el flujo completo está validado si no se ha comprobado recientemente.

Resultados del modelo registrado

Indicador	Resultado	Qué significa en este ejercicio
Exactitud (accuracy)	64,85 %	Porcentaje total de predicciones correctas; puede ser engañoso si las clases están desbalanceadas.
Precisión	7,55 %	Una proporción pequeña de las predicciones positivas fue correcta.
Sensibilidad (recall)	68,38 %	El modelo identificó una parte de los casos positivos sintéticos.

La matriz de confusión guardada contiene TN=1.796, FN=37, FP=980 y TP=80, sobre 2.893 casos de prueba. El número elevado de falsos positivos y la precisión baja indican que el modelo necesita revisión. Además, la variable de riesgo es sintética: el resultado sirve para explicar el procedimiento, no para tomar decisiones reales sobre estudiantes.

Para una siguiente versión, convendría describir claramente las variables usadas, la forma de construir la etiqueta, la partición de entrenamiento y prueba y los parámetros del modelo. También se debe explicar qué errores son más costosos y por qué.

6. Riesgos y cómo reducirlos

La guía pide considerar seis riesgos. La tabla resume por qué importan y qué controles ayudarían a reducirlos. La eficacia de esos controles debe probarse; escribirlos como recomendación no equivale a tenerlos implantados.

Riesgo	Qué podría ocurrir	Medidas recomendadas
Acceso no autorizado	Alguien consulta o modifica datos sin motivo legítimo.	Permisos por rol, mínimo privilegio, autenticación fuerte y revisión de accesos.
Duplicidad	Los reportes cuentan dos veces una persona o matrícula.	Claves únicas, detección de duplicados y conciliación de conteos.
Datos incorrectos	Los indicadores muestran cifras equivocadas.	Validar dominios, rangos, campos obligatorios e integridad referencial.
Pérdida de datos	No se puede recuperar la información después de un fallo.	Respaldos y pruebas de restauración; documentar cambios y recuperación.
Fuga de información	Se divulgan registros académicos o personales.	Minimizar datos, seudonimizar, limitar exportaciones y gestionar incidentes.
Falta de trazabilidad	No se puede explicar de dónde salió un indicador o cómo cambió.	Versionar scripts y registrar fuente, fecha, reglas, conteos y resultados.

Prioridades

En una institución real, el acceso indebido y la fuga de información merecerían atención especial por la sensibilidad de los registros. Los errores, duplicados y la falta de trazabilidad también afectan la confianza en los reportes. Para establecer prioridades definitivas, la universidad tendría que valorar probabilidad, impacto y controles existentes con sus responsables.

Si ocurre un incidente, debería existir una ruta clara para reportarlo, contenerlo, conservar evidencia, evaluar el alcance, informar a los responsables, recuperar el servicio y registrar las acciones correctivas. Trabajar con datos sintéticos reduce la exposición en esta práctica, pero no reemplaza esas medidas en producción.

7. Relación con DAMA-DMBOK y cierre

DAMA-DMBOK ayuda a ordenar el trabajo de datos más allá de la programación. En este proyecto, las áreas se relacionan con tareas concretas del caso de la siguiente manera:

Área de conocimiento	Aplicación en Universidad Nova
Gobierno de datos	Definir responsables, políticas, prioridades y seguimiento.
Arquitectura de datos	Separar datos de origen, analítica, procesamiento y visualización.
Modelado y diseño	Definir entidades, claves y relaciones coherentes.
Almacenamiento y operaciones	Administrar PostgreSQL, respaldo, disponibilidad y ejecución de procesos.
Seguridad de datos	Clasificar información, limitar accesos y preparar respuesta a incidentes.
Integración e interoperabilidad	Normalizar fuentes y controlar las cargas ETL.
Calidad de datos	Revisar completitud, unicidad, validez e integridad.
Metadatos	Documentar significado, origen, responsable y transformación.
Datos maestros y de referencia	Mantener identificadores y categorías consistentes.

Pendientes antes de la entrega

Falta confirmar la URL pública de GitHub, probar nuevamente los filtros del tablero, repetir la validación de extremo a extremo de Spark/sparklyr y guardar capturas reales. También debe grabarse el video explicativo de cinco minutos. Estos puntos son tareas de cierre y no deben darse por realizados hasta contar con la evidencia correspondiente.

Conclusiones

La práctica muestra cómo llevar datos simulados desde su preparación hasta una visualización, y permite explicar por qué el gobierno de datos es necesario para confiar en los indicadores. Sin embargo, la calidad de un modelo no se mide solo por una cifra de exactitud. En este caso, la precisión baja y los falsos positivos altos obligan a presentar el resultado con cautela. El siguiente avance debe centrarse en verificar la ejecución, documentar las evidencias y convertir las recomendaciones de gobierno en controles que puedan probarse.

Repositorio público: [añadir la URL real de GitHub antes de entregar].
Video: [añadir enlace o ubicación de entrega].

Marco de referencia: DAMA International, *DAMA-DMBOK: Data Management Body of Knowledge*. La organización del informe sigue las necesidades descritas en la guía académica del caso Universidad Nova.